

**CENTRO UNIVERSITÁRIO DE JOÃO PESSOA - UNIPÊ  
PRÓ-REITORIA ACADÊMICA – PROAC  
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO**

**NITAI CHARAN ÁLVARES PEREIRA**

**CONSULTAS UTILIZANDO LINGUAGEM NATURAL NO SERVIDOR DE BUSCA  
DISTRIBUÍDO ELASTICSEARCH**

**JOÃO PESSOA - PB**

**2019**

# **CONSULTAS UTILIZANDO LINGUAGEM NATURAL NO SERVIDOR DE BUSCA DISTRIBUÍDO ELASTICSEARCH**

Monografia apresentada ao Curso de Bacharelado em Ciência da Computação do Centro Universitário de João Pessoa - UNIPÊ, como pré-requisito para a obtenção do grau de Bacharel em Ciência da Computação, sob orientação do Prof. MS.c. Fábio Falcão da França.

**JOÃO PESSOA - PB**

**2019**

Nitai Charan Álvares Pereira

Consultas Utilizando Linguagem Natural no Servidor de Busca Distribuído Elastic-search/ Nitai Charan Álvares Pereira. – João Pessoa - PB, 2019-

22p. : il. (algumas color.) ; 30 cm.

Orientador: Fábio Falcão da França

Trabalho de Conclusão de Curso - TCC – Centro Universitário de João Pessoa - UNIPÊ, 2019.

1. Palavra-chave1. 2. Palavra-chave2. 2. Palavra-chave3. I. Orientador. II. Universidade xxx. III. Faculdade de xxx. IV. Título

**Nitai Charan Álvares Pereira**

## **Consultas Utilizando Linguagem Natural no Servidor de Busca Distribuído Elasticsearch**

Monografia apresentada ao Curso de Bacharelado em Ciência da Computação do Centro Universitário de João Pessoa - UNIPÊ, como pré-requisito para a obtenção do grau de Bacharel em Ciência da Computação, sob orientação do Prof. MS.c. Fábio Falcão da França.

Trabalho aprovado. João Pessoa - PB, 24 de novembro de 2012:

---

**Fábio Falcão da França**  
Orientador

---

**Professor**  
Convidado 1

---

**Professor**  
Convidado 2

João Pessoa - PB  
2019

*Dedico este trabalho ao meu professor orientador MSc. Fábio Falcão da França por me acolher e aconselhar passando seus conhecimentos sem pestanejos e me aceitando como último orientando antes de sua jornada em busca do título de doutorado. Dedico também ao professor MSc. Hugo Vieira Lucena de Souza por todos seus conselhos, ensinamentos e correções que foram possível para conclusão deste título. Também dedico este trabalho e ao professor DSc. Erick France Meira de Souza por sua amizade, suporte e preciosos conselhos dados.*

# Agradecimentos

Gostaria de agradecer minha avó Carminha (in memorian) e primo Luiz Felipe Abreu (in memorian).

Gostaria de agradecer aos meu pais Mathura Pati Devi Das e Subala Das por sempre prezar e batalhar pela educação dos seu filhos, sem medir esforços para que todos pudesse se graduar e obter a formação acadêmica necessária.

Meus agradecimentos também a minhas irmã Jahnavi Caran por me apoiar, dar suporte e aconselhar na minha trajetória acadêmica. Meus sinceros agradecimentos e minha eterna gratidão, irmã.

A todos os professores e pessoas não citadas diretamente neste texto, mas que participaram e contribuíram de alguma forma com a minha formação, meu muito obrigado.

*“Este trabalho é dedicado a criança a qual sempre falou que seria um cientista”*

# Resumo

Política de transparência públicas e fiscalização são essenciais para o controle do cidadão no controle e fiscalização de gastos públicos. Porém, tais cidadão certamente utilizaram como canal mediador entre entidade portadora dos dados para fiscalização pública e o cidadão que atua como fiscal neste cenário. Excluindo assim, pessoas leigas em elementos com teor tecnológico.

porém essas ferramentas apesar de apresentarem soluções eficazes muitas vezes não possuem um processo de inclusão realmente eficiente e condizente com a realidade do usuário final.

Muitas das aplicações existentes direcionadas ao público de portadores do espectro autista possuem como propósito auxiliar na comunicação e na aprendizagem da língua portuguesa ou de atividades do cotidiano, satisfazendo apenas campo específicos e havendo a real necessidade de mecanismos que auxiliem em outras áreas.

Portanto o presente trabalho tem o intuito de gerar uma aplicação de apoio ao ensino dos numerais de 1 a 9 para crianças portadoras do transtorno do espectro autista, utilizando um processo criativo baseado no usuário

, o Design Thinking, cujo objetivo principal é a resolução de problemas com foco primordial no ser humano, levando em consideração a realidade do público alvo, satisfazendo as suas necessidades e respeitando as suas limitações.

Através de ciclo de etapas baseados nesta metodologia foi possível realizar o desenvolvimento da solução proposta, cuja última etapa consiste na validação da solução, através da aplicação da mesma em campo por crianças portadoras do espectro. **Palavras-chave:** latex. abntex. editoração de texto.



1. Tecnologia no problema
2. Apresentar limitação das aplicações existentes
3. Mostrar que não há aplicações direcionadas a este propósito
4. Mostrar aplicação (solução) que ajudará no problema apresentado
5. Falar sobre a metodologia
6. Falar sobre o desenvolvimento da aplicação seguindo a metodologia

## Construção do Resumo

- Indicativo sobre o trabalho e não sobre o conteúdo do trabalho
- Entre 150 e 500 palavras
- Não usar abreviações, símbolos, formulas, equações ou diagramas a não ser que seja estritamente indispensáveis
- Não usar citações
- Não faça mais de um paragrafo
- Não crie tópicos
- Sem frases negativas
- Após o título do trabalho e nome dos autores
- Primeira frase indica o tema do trabalho
- Informar os objetivos geral e específicos, metodologia, resultados
- 3 a 5 palavras chaves que represente a essência do trabalho separadas por pontos

## Partes do Resumo

- Introdução  
Objetivos e relevância do trabalho do trabalho.
- Metodologia  
Elementos essenciais do método de pesquisa
- Resultados  
Principais resultados ou de maior destaque que pode ser representativo da pesquisa
- Discussão
- Conclusão  
Contribuição e limites do trabalho

## Normas ABNT resumo

- Frases afirmativas, curtas, escritas em voz ativa e na terceira pessoa do singular
- Texto claro, conciso, seguir uma ordem lógica e sem completamente fiel ao trabalho

- Deve mencionar o tema, objetivo, métodos, resultados e conclusões
- Deve indicar, no fim, palavras chaves

# Abstract

This is the english abstract.

**Keywords:** latex. abntex. text editoration.

# Lista de ilustrações

Figura 1 – JSON - Resposta da chamada a API. Comando: `curl http://localhost:9200/?pretty` 20

# Lista de abreviaturas e siglas

API	Application Programming Interface
LUIS	Language Understanding Intelligent Service
JSON	JavaScript Object Notation
IA	Inteligência Artificial
PLN	Processamento de Linguagem Natural
REST	Representational State Transfer

# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>15</b>
<b>1.1</b>	<b>Justificativa</b>	<b>15</b>
<b>1.2</b>	<b>Objetivos</b>	<b>16</b>
<b>1.2.1</b>	<b>Objetivo Geral</b>	<b>16</b>
<b>1.2.2</b>	<b>Objetivos Específicos</b>	<b>16</b>
<b>1.3</b>	<b>Metodologia</b>	<b>17</b>
<b>1.4</b>	<b>Organização do Trabalho</b>	<b>18</b>
<b>2</b>	<b>CONJUNTOS DE TECNOLOGIAS UTILIZADAS</b>	<b>19</b>
<b>2.1</b>	<b>ESTUDO A RESPEITO DO ELASTICSEARCH</b>	<b>19</b>
<b>2.2</b>	<b>INTELIGÊNCIA ARTIFICIAL</b>	<b>20</b>
<b>2.2.1</b>	<b>Processamento de Linguagem Natural (PLN)</b>	<b>20</b>
<b>2.3</b>	<b>ESTUDO A RESPEITO DA LANGUAGE UNDERSTANDING INTEL- LIGENT SERVICE</b>	<b>21</b>
	<b>REFERÊNCIAS</b>	<b>22</b>

# 1 Introdução

A barreira do aprendizado para a interação entre homem e sistemas computacionais até os dias atuais ainda é um obstáculo a ser conquistado devido a necessidade de tempo e interesse por parte dos usuário. (??) afirmam que usuários que se dispõem a aprender novos sistemas interativos com características únicas e distintas precisam dispor de tempo e interesse para posteriormente ser capazes de usufruir e usar as funcionalidades deste sistema.

Consequentemente, pessoas que não possuem hábito de utilização da internet e sem muito conhecimento técnico em manusear softwares de acesso podem deixar de participar de eventos, oportunidades e movimentos que utilizam como meio a internet. Pessoas com estas características podem se ausentar da participação no controle sobre a Administração Pública atuando na verificação, acompanhamento e fiscalização da regularidade de gastos públicos devido a se depararem com barreiras até mesmo no momento do recolhimento dos dados públicos que utilizam como canal mediador a internet.

No que se refere a fiscalização, com a promulgação da Constituição de 1988, o Brasil se classificou se como um Estado Democrático de Direito onde uma de suas características, para este tipo de estado, é a participação popular no controle sobre a Administração Pública. Neste sentido, o cidadão tem o poder de acompanhar e fiscalizar a regularidade dos atos governamentais juntamente com os órgãos institucionais legalmente criados para esta finalidade (??).

Tendo em vista que em 2000 foi promulgada a Lei de Responsabilidade Fiscal, que entre muito outros pontos, no artigo 48, definiu que as prestações de contas e outros instrumentos de transparência da gestão fiscal pública devem ter ampla divulgação, inclusive em meios eletrônicos de acesso público. Porém, todo benefício gerado a partir das regras impostas por esta lei, podem não ser devidamente aproveitadas por cidadãos que não possuem conhecimento prévio na utilização da internet.

Surgindo assim a pergunta central que este trabalho se propõe a intervir: como facilitar o acesso às informações públicas com o propósito que pessoas, sem conhecimento técnico em sistemas computacionais, possam auxiliar no processo de fiscalização de gastos governamentais, ajudando assim a diminuir os índices de corrupção no país?

## 1.1 Justificativa

A partir da promulgação da Lei de Acesso à Informação, Lei nº 12.527/2011, foi garantido o direito constitucional de acesso às informações públicas, possibilitando que qualquer pessoa física ou jurídica, sem a necessidade de apresentar motivos, receba informações públicas de órgãos e entidades. Desta forma, surgem novos mecanismos os quais possibilitam a participação



do cidadão na fiscalização de gastos públicos e combate à corrupção.

A melhoria do acesso à informação pública e a criação de regras que permitem a disseminação de informações produzidas pelo governo reduzem os abusos que podem ser cometidos (??). Porém, tais dados estão mais disponíveis em sistemas computacionais mediante a internet, utilizando-se muitas vezes de ferramentas carentes de parametrização ou disponibilização dos dados em grandes planilhas, dificultando assim o entendimento por parte de não-especialistas em informática.

Na tentativa de melhorar a divulgação dos dados públicos, o Ministério da Transparência em conjunto com a Controladoria-Geral da União, em 2004, criou o site Portal da Transparência do Governo Federal que possibilita o acesso livre, no qual o cidadão pode encontrar informações sobre como o dinheiro público é utilizado, além de se informar sobre assuntos relacionados à gestão pública do Brasil. Ainda assim, o problema de acesso por pessoas sem muitos conhecimentos técnicos sobre internet e como utilizá-la continua a existir.

Como forma de intervenção, este trabalho sugere a utilização de linguagem natural para busca e manipulação dos dados em bases de dados disponibilizadas pelo Governo Federal. “O processamento de linguagem natural permite ao computador compreender e reagir a declarações e comandos de voz realizados em uma linguagem natural” (??, p. 508). Para tal, este trabalho propõe a utilização do serviço de API de reconhecimento vocal Language Understanding Intelligent Service (LUIS) que aplica inteligência de aprendizado personalizado de máquina a um texto de linguagem natural e extrai informações relevantes a futuras aplicações. Para isso, este trabalho também propõe a utilização da ferramenta Elasticsearch que, entre muitas funcionalidades, possui recursos e tecnologias que permitem realizar consultas através de índices em grandes volumes de dados em tempo real (??).

## 1.2 Objetivos

### 1.2.1 Objetivo Geral

Desenvolver uma solução de software que utiliza Graphical User Interface (GUI) para aumentar a usabilidade a pessoas leigas. Recebe como entrada uma solicitação de consulta a dados públicos, em linguagem natural, e é respondida com ou sem os dados solicitados.

### 1.2.2 Objetivos Específicos

Realizar um estudo acerca dos conjuntos tecnologias utilizadas para a criação de um sistema de interação descrevendo suas características e possibilidades possíveis de utilização para se atingir o objetivo geral.

Gerar protótipos de baixa fidelidade para os testes de usabilidade com os requisitos impostas na concepção do sistema.

Avaliar a efetividade da aplicação com a realização de um estudo de caso uso solicitando a atores escolhidos de forma aleatória tentando buscar dados sobre gastos públicos sem e com a solução de software posposto.

## 1.3 Metodologia

“Método é o conjunto das atividades sistemáticas e racionais que, com maior segurança e economia, permite alcançar o objetivo de produzir conhecimentos válidos e verdadeiros, traçando o caminho a ser seguido, detectando erros e auxiliando as decisões” (??, p. 79). As autoras descrevem também que a ciência caracteriza-se pela utilização de métodos científicos e que estes não são de uso exclusivo pela ciência. Porém, não é possível a ciência estar apartado do emprego de métodos científicos (??).

Com o objetivo de facilitar análise e avaliações futuras, este trabalho é dividido sobre a características dos tipos de pesquisas que foram aplicada do processo de construção deste trabalho.

Este trabalho se classifica como pesquisa exploratória pois entre outros fatores é tentado proporcionar maior familiaridade com as ferramentas utilizadas pela solução de software proposta. Realizando para isso, levantamento bibliográficos com o propósito de explicar e expor possibilidades proporcionadas por estas ferramentas. Como (??) explana que o levantamento bibliográfico utilizada pelas pesquisas exploratórias é uma das maneiras utilizadas para a coleta de dados relevantes.

Este trabalho também se classifica como uma pesquisa aplicada devido ao propósito ser uma possível abordagem ao problema identificado da dificuldade de acesso às informações públicas em que pessoas, sem conhecimento técnico em sistemas computacionais, possam posteriormente auxiliar no processo de fiscalização de gastos governamentais. (??, p. 25) “pesquisa aplicada, abrange estudos elaborados com a finalidade de resolver problemas identificados no âmbito das sociedades em que os pesquisadores vivem”.

Com o intuito a avaliações futuras sobre a qualidade dos resultados mostrados neste trabalho, foi adotado a análise e interpretação dos dados expostos de forma qualitativa. Devido a descrição dos resultados serem em formas verbais e não em termos numéricos como proposto pelas pesquisas quantitativa. (??, p. 39) “Nas pesquisas quantitativas os resultados são apresentadas em termos numéricos e, nas qualitativas, mediante descrições verbais”.

Os procedimentos adotados na análise, interpretação e coleta dos dados exposto neste trabalho são realizados de forma bibliográfica e experimental. A forma bibliográfica se dá pela referenciação de dados através de citações de materiais já publicados. Enquanto que a experimental se dá pela adoção de testes de caso de uso utilizado para demonstrar a eficácia do software proposto para intervenção ao problema.

## 1.4 Organização do Trabalho

Após esse capítulo introdutório, o conteúdo deste trabalho organiza-se da seguinte forma:

- Capítulo <n> - DESENVOLVIMENTO DA SOLUÇÃO: apresentará a ferramenta proposta, assim como arquitetura de software, diagramas, mockups de telas e demais artefatos que contribuíram com o trabalho;
- Capítulo <n> - <TÍTULO>: apresentará quais teorias e respectivos autores mais contribuíram para a realização do estudo e as bases teóricas para a realização deste trabalho;
- Capítulo <n> - <TÍTULO>: apresentará os conceitos e as pesquisas que fundamentam a realização deste trabalho;
- Capítulo 2 - ESTUDO A RESPEITO DA API ELASTICSEARCH: apresentará um estudo detalhado a respeito da ferramenta utilizada para buscar, gravar e extrair informações de forma rápida e indexada;
- Capítulo 3 - ESTUDO A RESPEITO DA LANGUAGE UNDERSTANDING INTELLIGENT SERVICE (LUIS): apresentará um estudo detalhado a respeito da ferramenta de reconhecimento textual;
- Capítulo 4 - CONCLUSÃO: finaliza o trabalho apresentando os resultados obtidos, formas de utilizar o modelo para entender o desempenho dos alunos, discutindo os possíveis trabalhos futuros.

## 2 Conjuntos de Tecnologias utilizadas

Neste capítulo é mostrada uma proposta de abordagem a este problema através de uma aplicação a qual tem se como objetivo facilitar o acesso a dados públicos de forma facilitada através de linguagem natural.

### 2.1 ESTUDO A RESPEITO DO ELASTICSEARCH

Para busca e persistência dos dados será utilizado a tecnologia Elasticsearch que se caracteriza por ser um conjunto de mecanismo de busca open-source que realiza buscas e analisar dados em tempo real (??). Estas características são obtidas devido ao uso do conjunto de tecnologia agregado que o Elasticsearch possui. Através disso é criada soluções próprias que utilizam as facilidades tragas do conjunto para atingir seus objetivos.

Tendo como principal objetivo facilitar a busca por texto e a rapidez no acesso aos dados e gravação, o Elasticsearch possui a capacidade de funcionamento escalável sendo possível a utilização em apenas um servidor (*standalone*) ou de forma distribuída em centenas de servidores (??). Agilizando assim, a entrega ao usuário ou aplicação que solicitar os dados persistidos.

Para solicitar os dados persistido é disponibilizada uma interface RESTful API que possibilita a obtenção e visualização dos dados por aplicações *web client* (??). Esta funcionalidade disponibiliza a comunicação entre o Elasticsearch e outras aplicações independente como foi feito ou a linguagem da aplicação *web client*. Gerando assim, independência e maior usabilidade.

Possuindo como base o Apach Lucene, qualifica por ser atualmente a mais avançado, performática e completa livrara de motor de busca existente, é construído na linguagem Java para poder integrar e usufruir dessa livraria. Ao contrário, é necessário uma grande carga de conhecimento necessária para compreender como é realizado as facilidades tragas pelo Lucene devido a sua complexidade (??).

Um dos maiores benefícios tragos através da utilização do Apach Lucene é a ação de indexação. Utilizando disso, o Elasticsearch realiza busca, ordena, e filtra persisti dados fornecidos como objeto e documentos realizando a indexação em todas suas ações. Consequentemente, esta tecnologia também é caracterizado como orientado a documento (??).

Um documento é um dado constituído por campos, o qual pode se repetir por várias vezes. Todos os campos possui em tipo como texto, numérico, data, etc... Ou tipos mais complexos como subdocumentos ou *arrays*. Para cada documento persistido é salvo um pequeno título, data de publicação e um link de acesso ao conteúdo do persistido. O ato de se persistir um documento é chamado de indexação e o nome do dado persistido é chamado de índice (??).

Após a criação desta estrutura, é possível realizar pesquisas através de temas. Agilizando assim, a obtenção dos dados desejados. A disponibilização dos dados solicitados ocorre através de uma simples API RESTful mediante a transformação e transporte dos dados no formato *JavaScript Object Notation*(JSON) como exemplificado na [Figura 1](#).

Figura 1 – JSON - Resposta da chamada a API. Comando: `curl http://localhost:9200/?pretty`

```
{
  "name" : "XsyRmrG",
  "cluster_name" : "elasticsearch",
  "cluster_uuid" : "4sw9BMjIS_Sx_iqYfWfIRg",
  "version" : {
    "number" : "6.6.0",
    "build_flavor" : "oss",
    "build_type" : "zip",
    "build_hash" : "a9861f4",
    "build_date" : "2019-01-24T11:27:09.439740Z",
    "build_snapshot" : false,
    "lucene_version" : "7.6.0",
    "minimum_wire_compatibility_version" : "5.6.0",
    "minimum_index_compatibility_version" : "5.0.0"
  },
  "tagline" : "You Know, for Search"
}
```

Fonte: Autor

## 2.2 INTELIGÊNCIA ARTIFICIAL

Inteligência Artificial é uma das ramificações da ciências computacionais que se dedica ao estudo de tentar simular a inteligência humana em maquinas, desenvolver a inteligência artificial de máquinas e softwares que podem raciocinar, aprender, reunir conhecimento, comunicar, manipular e perceber objetos. Inteligência é comumente considerado como a capacidade de resolver problemas complexos realizando previamente coleta de informações e conhecimentos (??).

### 2.2.1 Processamento de Linguagem Natural (PLN)

Processamento de Linguagem Natural (PLN) é uma subárea da Inteligência Artificial (IA) que estuda as limitações, problemas e compreensão da linguagem humana para resoluções de problemas solúveis através de uma inteligência artificial. Seu objetivo principal é possibilitar maquinas entenderem e interpretarem a linguagem humana. Tal processo converte dados em texto em formatos que máquinas entendam como o numérico e binário (??).

Este processo é baseado em quatro etapas para extrair informações pertinentes do texto alvo. Primeiro o texto é realizado um processo que criação de *tokens* das palavras do texto. Nesta etapa o texto é quebrado em unidades, sem se preocupar no significado ou classificação

gramatical das palavras. Formando assim uma lista de *tokens* que será usada em todos os outros processo com seus diferentes objetivos (??).

A segunda etapa é dedicada a detecção de sentenças utilizando unidades criados na primeira etapa. A combinação de palavras em uma frase ou uma sentença pode ter diferentes significados mudando o relacionamento entre outras palavra ou outras sentenças. Pode ser dado como exemplo que, frequente é distinguido a função gramatical entre as palavras como substantivo e verbos (??).

A terceira é o processo de classificada cada palavra e documentos que consiste na rotulação destas informações encontradas no texto. No processo de rotulação, o rótulo pode ou não existir antes desta etapa. Caso exista, esta etapa é chamada de classificação. Antagônico, é chamado de agrupamento (??).

A quarta etapa é o processo de extração de relacionamentos identificado no texto. Esta etapa é útil para uma série de tarefas, incluindo a construção de bases de conhecimento, análise de tendências, coleta de inteligência e realização de pesquisas de produtos (??).

## 2.3 ESTUDO A RESPEITO DA LANGUAGE UNDERSTANDING INTELLIGENT SERVICE

Language Understanding Intelligent Service (LUIS) é uma suite de *software* pertencente a um dos Serviços Cognitivos da Microsoft que utiliza um ramo da Inteligência Artificial (IA) chamado Processamento de Linguagem Natural (PLN) (??). Essa suite, possibilita que aplicações possam adquirir certo grau de inteligência. Formando assim, seu objetivo central da utilização.

O objetivo de utilização desta ferramenta é possibilitar a tradução de linguagem natural em texto plano para que programas de computadores possam entender e interagir utilizando tais dados. Para isso, a API extrai de uma sentença do tipo texto em linguagem natural as intenções e entidades, retornando após objetos no formato JavaScript Object Notation (JSON) (??).

Previamente, é necessário a criação de modelos de linguagens para extração das entidades e intenções. Qualquer objeto, seja ele abstrato ou concreto, podem ser caracterizados como entidades. Exemplos como lugares, tempo e números podem ser definidos como entidades alvo. Consequentemente possibilitando o reconhecimento de comandos dos usuários em entradas como frases ou sentenças em linguagem natural (??).

Porém, a LUIS não é uma aplicação cliente que deve conversar e solicitar dados ao cliente. LUIS possibilita para que outras aplicações como *chatbots*, *websites*, aplicativos móveis ou aplicações *desktops* possam se comunicar mediante a *internet* via API. Servido como um tradutor à aplicações se comunicarem e entenderem os desejos dos usuários.

## Referências